exam-module3-airbnb

November 30, 2020

1 Módulos utilizados

```
[]: import pandas as pd
   import numpy as np
   import matplotlib.pyplot as plt
   import seaborn as sns
   import urllib
   from scipy.stats import norm
   from scipy import stats
   from sklearn import preprocessing
   from sklearn.preprocessing import LabelEncoder
   from sklearn.preprocessing import StandardScaler
   from sklearn.model_selection import train_test_split
   from sklearn.model_selection import KFold
   from sklearn.model_selection import GridSearchCV
   from sklearn.ensemble import ExtraTreesClassifier
   from sklearn.linear_model import LinearRegression
   # from sklearn.preprocessing import PolynomialFeatures
   # from sklearn.linear_model import Ridge
   # from sklearn.linear_model import Lasso
   # from sklearn.linear_model import ElasticNet
   from sklearn import metrics
   from sklearn.metrics import mean_squared_error
   from sklearn.metrics import mean_absolute_error
   from math import sqrt
   from sklearn.metrics import r2_score
```

2 Preparación del dataset

[5]: cd /content/drive/MyDrive/CURSOS/EOI/Python-Developer-EOI/module3/examen

/content/drive/MyDrive/CURSOS/EOI/Python-Developer-EOI/module3/examen

```
[]: # Lectura del dataset
   filename = 'AB NYC 2019.csv'
   data = pd.read_csv(filename)
[]: # Primeras filas
   data.head()
[]:
        id ... availability_365
   0 2539
                              365
   1 2595 ...
                              355
   2 3647 ...
                              365
   3 3831 ...
                              194
   4 5022 ...
                                0
   [5 rows x 16 columns]
[]: # Busco valores nulos que puedan perjudicar mi análisis para eliminarlos
   # posteriormente en caso de que no sean necesarios
   data.isnull().sum()
[]: id
                                          0
   name
                                         16
                                          0
   host_id
   host_name
                                         21
   neighbourhood_group
                                          0
                                          0
   neighbourhood
   latitude
                                          0
                                          0
   longitude
   room_type
                                          0
                                          0
   price
   minimum_nights
                                          0
   number_of_reviews
                                          0
   last_review
                                      10052
   reviews_per_month
                                      10052
   calculated_host_listings_count
                                          0
   availability_365
                                          0
   dtype: int64
```

3 Exploratory Data Analysis

```
[]: # Relación entre el precio y el tipo de habitación

# El precio de la habitación compartida siempre es inferior a 2000 dólares

# Las habitaciones privadas y las propiedades completas tienen los precios más

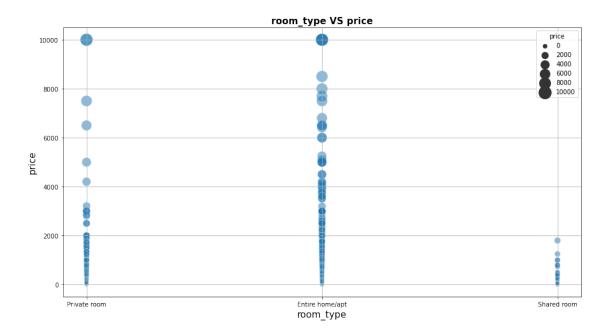
→ altos

plt.figure(figsize=(15, 8))

sns.scatterplot(x='room_type', y='price', data=data, sizes=(40, 400), alpha=.5, 
→ size="price")
```

```
plt.xlabel("room_type", size=15)
plt.ylabel("price", size=15)
plt.grid(b=True)
plt.title("room_type VS price", size=15, weight='bold')
```

[]: Text(0.5, 1.0, 'room_type VS price')

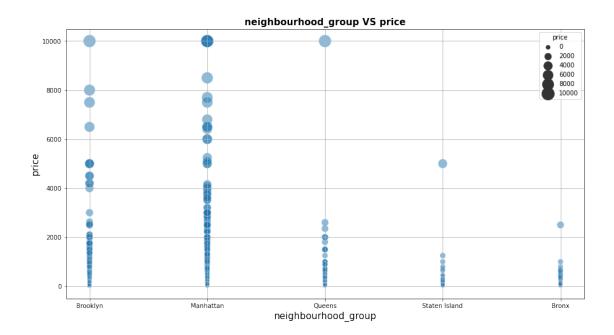


```
[]: # Las áreas con mayor concetración de propiedas son Brooklyn y Manhattan, así
# como aquellas con mayor dispersión en los precios

plt.figure(figsize=(15, 8))
sns.scatterplot(x='neighbourhood_group', y='price', data=data, sizes=(40, 400),
alpha=.5, size="price")

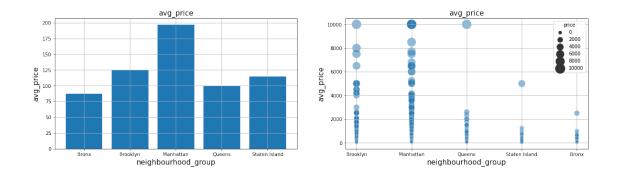
plt.xlabel("neighbourhood_group", size=15)
plt.ylabel("price", size=15)
plt.grid(b=True)
plt.title("neighbourhood_group VS price", size=15, weight='bold')
```

[]: Text(0.5, 1.0, 'neighbourhood_group VS price')



```
[]: # En estas gráficas, se puede ver que el precio medio no es un buen indicador
    \rightarrowen
   # este análisis, ya que hay una desviación muy fuerte en los precios
   fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(20,5))
   ax1.bar(sorted(data.neighbourhood_group.unique()), data.

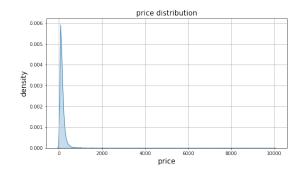
¬groupby('neighbourhood_group').mean()['price'])
   ax1.set xlabel("neighbourhood group", size=15)
   ax1.set_ylabel("avg_price", size=15)
   ax1.set_title("avg_price", size=15)
   ax1.grid(b=True)
   sns.scatterplot(x='neighbourhood_group', y='price', data=data, sizes=(40, 400),
    →alpha=.5, size="price", ax=ax2)
   ax2.set_xlabel("neighbourhood_group", size=15)
   ax2.set_ylabel("avg_price", size=15)
   ax2.set_title("avg_price", size=15)
   ax2.grid(b=True)
```

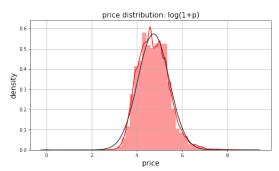


```
[]: # Añado un campo con la transformación logarítimica, de forma que el análisis,
    →de los datos y sus interpretación sea más sencilla
   data['price_log'] = np.log(data.price + 1)
   # En la gráfica azul, pueve verse que hay una distribución de precios muy∟
    ⇒sesqada (concretamente, sesqo positivo)
   # En la gráfica roja, los precios siguen una distribución \log(1+p)_{\sqcup}
    → (transformación logarítmica)
   fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(20,5))
   sns.kdeplot(data.price, shade=True, ax=ax1)
   ax1.set_xlabel("price", size=15)
   ax1.set_ylabel("density", size=15)
   ax1.set title("price distribution", size=15)
   ax1.grid(b=True)
   sns.distplot(data.price_log, fit=norm, ax=ax2, color='r')
   ax2.set_xlabel("price", size=15)
   ax2.set_ylabel("density", size=15)
   ax2.set_title("price distribution: log(1+p)", size=15)
   ax2.grid(b=True)
```

/usr/local/lib/python3.6/dist-packages/seaborn/distributions.py:2551: FutureWarning: `distplot` is a deprecated function and will be removed in a future version. Please adapt your code to use either `displot` (a figure-level function with similar flexibility) or `histplot` (an axes-level function for histograms).

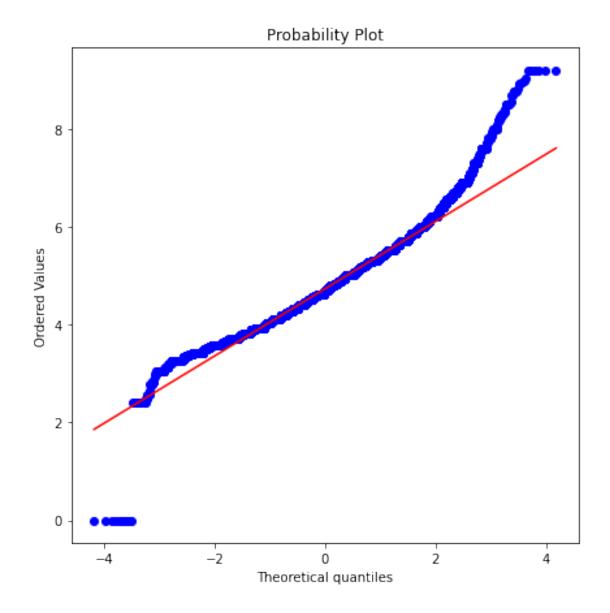
warnings.warn(msg, FutureWarning)





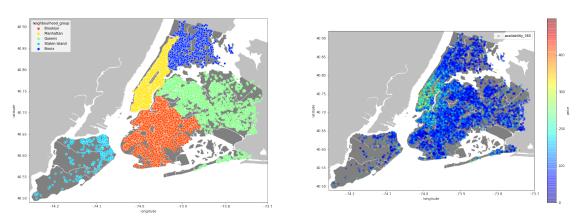
```
[]: # Prueba de normalidad para determinar si el conjunto de datos está bienu modelado por una distribución normal plt.figure(figsize=(7, 7)) stats.probplot(data.price_log, plot=plt)

[]: ((array([-4.18631264, -3.98032736, -3.86801681, ..., 3.86801681, 3.98032736, 4.18631264]), array([0. , 0. , 0. , ..., 9.21044037, 9.21044037, 9.21044037])), (0.6871218845318134, 4.736884710386776, 0.9881016272577388))
```



/usr/local/lib/python3.6/dist-packages/seaborn/_decorators.py:43: FutureWarning: Pass the following variables as keyword args: x, y. From version 0.12, the only valid positional argument will be `data`, and passing other arguments without an explicit keyword will result in an error or misinterpretation.

FutureWarning



4 Model Building

```
[]: # Preparo los datos para elaborar el modelo y elimino datos no necesarios 
# 'dmodel' (data model) es un nuevo DataFrame con los datos necesarios para la_
→ elaboración del modelo

# De entre los datos que se eliminan, destaco que elimino la columna 'price', 
→ ya que usaré de aquí en adelante 'price_log', que es su distribución 
→ logarítmica

dmodel = data.drop(columns=['name', 'id', 'host_id', 'host_name', 
→ 'last_review', 'price'])
```

```
dmodel.isnull().sum()
[]: neighbourhood_group
                                          0
   neighbourhood
                                          0
   latitude
                                          0
   longitude
                                          0
                                          0
   room_type
                                          0
   minimum_nights
   number_of_reviews
                                          0
                                      10052
   reviews_per_month
   calculated_host_listings_count
                                          0
   availability_365
                                          0
   price_log
                                          0
   dtype: int64
[]: # El número de reviews tiene algunos datos faltantes, los cuales voy a
    →reemplazar por la media, ya que estos datos son más simétricos (no presentanu
    →una alta desviación)
   # De esta forma, ya no tengo datos faltantes (ni null ni NaN)
   mean = dmodel['reviews_per_month'].mean()
   dmodel['reviews_per_month'].fillna(mean, inplace=True)
   dmodel.isnull().sum()
[]: neighbourhood_group
                                      0
   neighbourhood
                                      0
                                      0
   latitude
                                      0
   longitude
   room_type
                                      0
                                      0
   minimum nights
   number_of_reviews
                                      0
   reviews_per_month
   calculated_host_listings_count
   availability_365
                                      0
                                      0
   price_log
   dtype: int64
[]: # Matrices de correlación (con distintos métodos)
   fig, (ax1, ax2, ax3) = plt.subplots(1, 3, figsize=(30, 5))
   # Correlación (método de Pearson)
   corr1 = dmodel.corr(method='pearson')
   sns.heatmap(corr1, annot=True, ax=ax1)
   ax1.set_title("Pearson method", size=15)
   # Correlación (método de Kendall)
   corr2 = dmodel.corr(method='kendall')
   sns.heatmap(corr2, annot=True, ax=ax2)
   ax2.set_title("Kendall method", size=15)
```

```
# Correlación (método de Spearman)

corr3 = dmodel.corr(method='spearman')

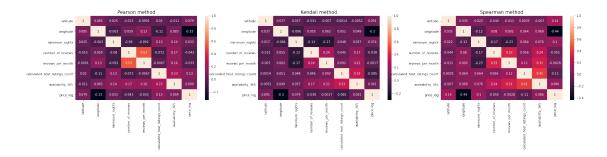
sns.heatmap(corr3, annot=True, ax=ax3)

ax3.set_title("Spearman method", size=15)

# De acuerdo con las matrices de correlación, no hay fuerte relación entre el⊔

→precios y otras variables, por lo que no es necesario eliminar más datos
```

[]: Text(0.5, 1.0, 'Spearman method')



```
[]: # La multicolinealidad ayuda a medir la relación entre las variables⊔

→explicativas en la regresión múltiple

# Si se da la multicolinealidad, estas variables de entrada altamente⊔

→relacionadas deben ser eliminadas (no incluidas en el modelo)

# Dicha multicolinealidad debe ser controlada con los autovectores

# Voy a tomar la matriz de correlación obtenida con el método de Pearson

multicollinearity, V = np.linalg.eig(corr2)

multicollinearity

# Ninguno de los valores propios de la matriz de correlación es cercano a cero, □

→por lo que no existe multicolinealidad en los datos
```

[]: array([1.62323446, 1.32545299, 1.18263489, 1.02120012, 0.57642321, 0.69351065, 0.74803324, 0.82951044])

```
[]: # Voy a reescalar los datos de forma que cada feature tenga media 0 y<sub>□</sub>

→ desviación estándar unidad

dmodel_x = dmodel.drop(columns=['neighbourhood_group', 'neighbourhood', □

→ 'room_type'])

dmodel_y = dmodel.drop(columns=['neighbourhood_group', 'neighbourhood', □

→ 'room_type'])

scaler = StandardScaler()

dmodel_x = scaler.fit_transform(dmodel_x)
```

[]: X_train, X_test, y_train, y_test = train_test_split(dmodel_x, dmodel_y,__

\$\text_\size=0.3\$, random_state=42)

5 Linear Regression

```
[]: def linear_reg(input_x, input_y, cv=5):
       ## Defining parameters
       model_LR= LinearRegression()
       parameters = {'fit_intercept': [True,False], 'normalize': [True,False],__

¬'copy_X':[True, False]}
        ## Building Grid Search algorithm with cross-validation and Mean Squared
    \rightarrowError score.
       grid_search_LR = GridSearchCV(estimator=model_LR,
                             param_grid=parameters,
                             scoring='neg_mean_squared_error',
                             n jobs=-1)
       ## Lastly, finding the best parameters.
       grid_search_LR.fit(input_x, input_y)
       best_parameters_LR = grid_search_LR.best_params_
       best_score_LR = grid_search_LR.best_score_
       print(best_parameters_LR)
       print(best_score_LR)
   # linear_reg(nyc_model_x, nyc_model_y)
```

6 Model Prediction

```
[]: lr = LinearRegression(copy_X= True, fit_intercept = True, normalize = True)
lr.fit(X_train, y_train)
lr_pred= lr.predict(X_test)
```

7 Exportar a PDF

[NbConvertApp] Converting notebook exam-module3-airbnb.ipynb to pdf [NbConvertApp] Support files will be in exam-module3-airbnb_files/

```
[NbConvertApp] Making directory ./exam-module3-airbnb_files
[NbConvertApp] Making directory ./exam-module3-airbnb_files
[NbConvertApp] Making directory ./exam-module3-airbnb_files
[NbConvertApp] Making directory ./exam-module3-airbnb_files
[NbConvertApp] Making directory ./exam-module3-airbnb files
[NbConvertApp] Making directory ./exam-module3-airbnb_files
[NbConvertApp] Making directory ./exam-module3-airbnb files
[NbConvertApp] Writing 77856 bytes to ./notebook.tex
[NbConvertApp] Building PDF
[NbConvertApp] Running xelatex 3 times: [u'xelatex', u'./notebook.tex',
'-quiet']
[NbConvertApp] Running bibtex 1 time: [u'bibtex', u'./notebook']
[NbConvertApp] WARNING | bibtex had problems, most likely because there were no
citations
[NbConvertApp] PDF successfully created
[NbConvertApp] Writing 827760 bytes to exam-module3-airbnb.pdf
```

[11]: ls -1

```
total 9965
-rw----- 1 root root 7077973 Oct 27 2019 AB_NYC_2019.csv
-rw----- 1 root root 922326 Nov 30 17:19 examen-modulo3-airbnb.ipynb
-rw----- 1 root root 1182513 Nov 30 21:51 exam-module3-airbnb.ipynb
-rw----- 1 root root 827760 Nov 30 21:51 exam-module3-airbnb.pdf
-rw----- 1 root root 192340 Nov 30 12:08 New_York_City_.png
```